

Laboratorio 5

Deep Learning

Repositorio: <https://github.com/TheDeloz-v2/DL-LAB5>

Preguntas

1. *¿Cómo afecta la cantidad de parámetros del modelo? ¿Qué nos dicen eso 9M de parametros del modelo que hemos creado?*

El modelo con 9 millones de parámetros es considerablemente grande, lo que sugiere que tiene una alta capacidad para aprender patrones complejos en los datos. Sin embargo, esta cantidad de parámetros también implica un mayor riesgo de sobreajuste, especialmente si el conjunto de datos no es lo suficientemente extenso o diverso. Un modelo de este tamaño requiere un balance cuidadoso, donde se necesita suficiente regularización y una cantidad adecuada de datos para asegurar que pueda generalizar bien a nuevos ejemplos. Además, un modelo con tantos parámetros conlleva un mayor costo computacional en términos de memoria y tiempo de entrenamiento, lo que debe considerarse al evaluar su implementación en producción.

2. *¿Qué hace el algoritmo de inicialización de Xavier Uniform?*

Este algoritmo inicializa los pesos del modelo con valores en un rango uniforme determinado para mantener la varianza de las activaciones constante a lo largo de las capas. Esto ayuda a evitar problemas como el desvanecimiento o explosión de gradientes durante el entrenamiento.

3. *¿Qué hace el comando `torch.no_grad()`?*

Este comando desactiva la operación de cálculo de gradientes. Se utiliza comúnmente durante la evaluación de un modelo para ahorrar memoria y mejorar la eficiencia, ya que no se necesitan los gradientes para la retropropagación en esta fase.

4. *Interprete el valor obtenido para el BLEU score ¿es nuestro modelo un buen modelo?*

El BLEU score obtenido de 35.42 indica que el modelo de traducción automática es razonablemente eficaz. Este puntaje sugiere que el modelo está capturando una buena parte de las traducciones correctamente en comparación con las referencias humanas, aunque no es perfecto. Un BLEU score por encima de 30 se considera decente en muchas aplicaciones de traducción, lo que significa que el modelo genera traducciones que, en su mayoría, son precisas y coherentes. Sin embargo, todavía hay margen de mejora, y el modelo podría beneficiarse de ajustes adicionales, como un mayor conjunto de datos de entrenamiento, ajuste fino de hiperparámetros, o técnicas de regularización, para mejorar su rendimiento general y abordar posibles fallos en contextos más complejos.

5. *¿Qué puede observar de las palabras donde el modelo se ha confundido?*

Las palabras en las que se confunde el modelo nos dan un avistamiento de sus debilidades. Los errores comunes incluyen una confusión entre sinónimos, manejo de palabras extrañas o que no se encuentran en el vocabulario o con dificultades en algunas estructuras gramaticales.

6. *Observe el comportamiento de la pérdida y PPL en training y validation mientras se entrega el modelo, ¿qué puede decir de estos valores?*

Al observar los resultados de pérdida (Loss) y perplejidad (PPL) a lo largo de las 10 épocas, se puede ver que el modelo muestra un comportamiento consistente y positivo durante el entrenamiento. La pérdida de entrenamiento disminuye progresivamente de 4.256 en la primera época a 0.969 en la décima, lo que indica que el modelo está aprendiendo y ajustando sus parámetros de manera efectiva. Esta disminución constante en la pérdida sugiere que el modelo se está adaptando bien a los datos de entrenamiento.

Por otro lado, la pérdida en el conjunto de validación también disminuye, aunque de manera menos pronunciada, pasando de 3.055 en la primera época a 1.652 en la décima. Esta tendencia es una señal alentadora de que el modelo no solo está mejorando en el conjunto de entrenamiento, sino que también está mejorando su rendimiento en el conjunto de validación, lo que indica que no está sobreajustando los datos de entrenamiento de manera significativa.

En cuanto a la perplejidad (PPL), se observa un decremento notable en ambos conjuntos, lo cual refuerza la idea de que el modelo está aprendiendo a predecir de manera más efectiva las secuencias de datos. La PPL en el conjunto de entrenamiento disminuye de 70.532 a 2.635, mientras que en el conjunto de validación baja de 21.226

a 5.217. Esta mejora en la PPL en ambos conjuntos indica que el modelo está generalizando bien y mantiene su capacidad de predecir correctamente en datos no vistos.

Todo esto nos muestra que los resultados en el modelo se están ajustando de buena forma y generalizando de manera adecuada.

7. *Si bien no es una tarea intuitiva o sencilla la interpretación de las gráficas de attention que hemos realizado, intente darle una interpretación a la última de estas gráficas mostrada. ¿Qué tipo de insights podría sacar de esta gráfica?*

La última gráfica de atención en la imagen muestra cómo el modelo asigna importancia a las palabras de la secuencia de entrada en inglés mientras genera la secuencia de salida en alemán. Una característica importante de esta gráfica es la diagonal clara que atraviesa la gráfica, indicando que el modelo está alineando correctamente las palabras individuales entre las dos lenguas. Esta alineación directa es un buen indicio de que el modelo está capturando bien las correspondencias palabra por palabra, lo cual es esencial para una traducción precisa.

Sin embargo, también se observa que en ciertas áreas, la atención se dispersa más allá de esta diagonal. Esta dispersión sugiere que el modelo está considerando múltiples dependencias contextuales para algunas palabras, como "beautiful" y "day", donde las estructuras gramaticales entre el inglés y el alemán pueden diferir. Esto refleja la capacidad del modelo para manejar la complejidad de las traducciones, especialmente en casos donde la estructura de la oración no es tan directa entre las dos lenguas.

Esta gráfica de atención sugiere que el modelo tiene una comprensión sólida de las alineaciones entre las oraciones en inglés y alemán, pero también resalta áreas donde el modelo podría estar luchando con la complejidad lingüística, lo que podría ser un foco para futuras mejoras.